paperNotes

Favorites	☐
Notebook	thesis
Tags	
Last edited time	April 22, 2026 11:52 AM
Archive	☐
Created time	February 23, 2026 1:50 PM

数据集

https://huggingface.co/datasets/DAMO-NLP-SG/MultiJail

https://github.com/NISPLab/JBShield

> https://github.com/mainlp/Multilingual-Refusal

related works

1. Refusal Direction is Universal Across Safety-Aligned Languages（NeurIPS 2025.12）

逻辑：

拒绝方向在所有语言中通用（向量平行）
↓
但非英语语言的 harmful/harmless 分离质量差
↓
模型"有工具拒绝"但"识别不清是否有害"
↓
导致非英语jailbreak更容易成功

拒绝机制的跨语言泛化失败:

LLM在拒绝有害请求时，模型内部有一个特定的refusal direction, 一个在activation space中的向量，代表模型"要拒绝"这个倾向。

操控这个向量就能操控模型行为：

- **删除它** → 模型失去拒绝能力，开始顺从有害请求
- **加强它** → 模型变得更难被绕过

这个机制之前只在英语下被验证过。这篇论文问的是：**其他语言也有同样的向量吗？**

结论1: 拒绝方向是跨语言通用的

实验：从英语数据中提取refusal vector，然后把它删掉，看其他语言的模型是否也失去拒绝能力。

结果：是的，几乎所有语言的拒绝行为都崩溃了，顺从率普遍飙升至90%以上。

更惊人的是，从中文、德语、泰语提取的refusal vector，删掉之后也能让**其他所有语言**失去拒绝能力。

结论：LLM用同一个底层向量编码所有语言的拒绝行为，这个向量是语言无关的。

结论2: 非英语语言的有害/无害分离更差

这是最关键的一个发现，也是和你的研究直接相关的部分。

论文用**Silhouette Score**量化了每种语言下，harmful和harmless prompt在表示空间中分得有多开：

limitation：分析了原因没有提出优化方法；语言选择不够完善， 只有一个约鲁巴语低资源语言

2. JBShield: Defending Large Language Models from Jailbreak Attacks through Activated Concept Analysis and Manipulation（USENIX Security Symposium2025.8）

论文基于**线性表示假说（LRH）**，提出两个核心概念：**Toxic Concept， Jailbreak Concept**

模型"看见"了有害内容，但jailbreak concept压制了toxic concept的影响，导致模型顺从。

方法框架：JBShield

输入prompt
↓
[JBShield-D 检测]
提取toxic concept → 与anchor比对
提取jailbreak concept → 与anchor比对
两者都激活 → 判定为jailbreak prompt
↓
[JBShield-M 缓解]
增强 toxic concept（让模型更警觉）
削弱 jailbreak concept（减少顺从倾向）
↓
安全输出

3. MULTILINGUAL JAILBREAK CHALLENGES IN LARGE LANGUAGE MODELS(ICLR 2024.5)

论文把多语言jailbreak分为两类：

非故意场景（Unintentional）
普通用户只是用母语提问，没有恶意，但不小心绕过了安全机制。

故意场景（Intentional）
恶意用户主动把英语恶意指令翻译成其他语言，刻意发动攻击

发现多语言越狱现象

Unintentional: 其他低资源语言提问 绕过安全机制产生恶意回答

intentional: 恶意指令和低资源语言结合

提出 self defence微调 让模型自己生成多语言安全训练数据，然后用这些数据微调模型;安全性提升的同时，模型的通用能力有所下降（safety-usefulness trade-off），安全训练数据比例越高，有用性损失越大。

limitation：

对数据集要求高 语言很多 数据集需要一直完善

只说了现象 没有分析机制

4 Revisiting Jailbreaking for Large Language Models: A Representation Engineering Perspective（COLING 2025.1）

提出safety pattern， 每一层低方差特征维度构成的空间

limitation：分析机制 没有优化方法

general safety vector： 选一层， 算均值， **所有维度都保留**

5 Jailbreaking Large Language Models: Techniques, Trends, Defenses, and Open Challenges(IEEE International Conference on AI in Cybersecurity 2026.2)

综述

多语言攻击明确归类为"表示操控"的一个子类，并量化了其严重性（<1% vs 79%）。

在防御建议中对跨语言攻击的应对方案只写了翻译成英语再过滤、扩充多语言对齐数据、拒绝不支持语言三个方法

```
┌──────────────────────────────────────────────────────────────┐
│          LLM 内部存在拒绝机制                                  │
│                                                              │
│  论文4（COLING 2025）                                          │
│  Safety Pattern：每层低方差特征维度构成的子空间                  │
│  安全向量：选一层，算均值，保留所有维度                          │
└──────────────────────────────┬───────────────────────────────┘
                               │
                               │ 英语下验证有效
                               │ 但其他语言呢？
                               ↓
┌──────────────────────────────────────────────────────────────┐
```

```
│          拒绝机制的跨语言表现                    │
│                                                  │
│  论文1（NeurIPS 2025）                           │
│  发现1：拒绝方向跨语言通用（向量平行）              │
│  发现2：BUT 非英语语言的有害/无害分离质量更差        │
│                                                  │
│       有工具拒绝 ≠ 能识别是否有害                 │
└──────────────────────────────────────────────────┘
                          │
                          │
                          │ 分离质量差
                          │ 为什么？
                          ↓
┌──────────────────────────────────────────────────┐
│          更底层的机制解释                         │
│                                                  │
│  论文2（USENIX Security 2025）                   │
│  toxic concept    → 模型看见了有害内容            │
│  jailbreak concept → 压制了toxic concept的影响    │
│                                                  │
│  结果：模型"知道有害"但还是顺从了                  │
└──────────────────────────────────────────────────┘
                          │
                          │
                          │ 攻击者如何利用这个漏洞？
                          ↓
┌──────────────────────────────────────────────────┐
│          多语言越狱攻击的实际威胁                  │
│                                                  │
│  论文3（ICLR 2024）                              │
│  无意场景：普通用户用母语提问 → 意外绕过           │
│  有意场景：恶意指令 × 低资源语言 → 主动攻击        │
│                                                  │
│  严重程度（论文5）：英语拒绝率>99% vs 某些语言<21%  │
└──────────────────────────────────────────────────┘
                          │
                          │
                          │ 现有防御够用吗？
                          ↓
```

```
┌──────────────────────────────────────────────────────────────┐
│        现有防御方案的局限                                      │
│                                                              │
│ 论文3：self-defence微调                                        │
│   → safety提升但usefulness下降                                 │
│                                                              │
│ 论文5综述中的方案：                                            │
│  翻译成英语再过滤  → 翻译误差，成本高                            │
│  扩充多语言对齐数据 → 数据获取难，覆盖不全                        │
│  拒绝不支持语言   → 严重损害可用性                              │
│                                                              │
│ 论文2 JBShield：                                              │
│   → 只在英语下验证，未扩展到多语言                               │
└──────────────────────────────┬───────────────────────────────┘
                               │
                               ↓
┌──────────────────────────────────────────────────────────────┐
│              核心 GAP                                          │
│                                                              │
│ 现有工作要么只分析机制没有优化方法（论文1、4）                    │
│ 要么优化方法有usefulness损失（论文3）                            │
│ 要么只在英语下有效（论文2）                                      │
│                                                              │
│ → 如何在表示层面增强多语言场景下的                               │
│  有害内容识别能力，同时不损失模型通用能力？                       │
└──────────────────────────────────────────────────────────────┘
```